

ОСНОВЫ LLM 2026: Задание 3, RAG

Барлыбай Мадиев, ВМК-31

22 марта 2026 г.

1 Отчёт по заданию

В рамках задания был использован датасет `bearberry/rus_xquadqa`. Из всех примеров датасета были извлечены сегменты контекста и объединены в единый корпус. Повторяющиеся сегменты были удалены, после чего корпус был проиндексирован во векторной базе `Qdrant` в режиме `:memory:`.

Для векторизации корпуса использовалась `multilingual E5`-модель эмбедингов. Поиск по корпусу был реализован через `LangChain` и `QdrantVectorStore`. Далее на основе поиска и генеративной модели была построена RAG-система, которая для каждого вопроса извлекала релевантные фрагменты контекста и формировала ответ.

Для сравнения были выбраны две модели:

- `lmqg/mt5-small-ruquad-qa`
- `vocabtrimmer/mt5-small-trimmed-ru-90000-ruquad-qa`

Оценка проводилась на первых 10 вопросах датасета с сравнением предсказаний моделей с эталонными ответами. Полученные результаты:

- `lmqg/mt5-small-ruquad-qa`: **0.3**
- `vocabtrimmer/mt5-small-trimmed-ru-90000-ruquad-qa`: **0.4**

Таким образом, вторая модель показала лучший результат на выбранной выборке. Несмотря на небольшой объём тестирования, система показала, что может работать с подходом RAG для русскоязычной question answering задачи.